

面向 6G 的 AI 原生频谱认知技术

——以 LWM-Spectro 为例

摘 要

频谱认知是 6G 物理层从“盲通信”走向“环境感知”的核心使能技术。传统自动调制识别依赖人工特征工程和专用小模型，泛化能力受限于特定信号制式和信道条件。2025 年以来，受大语言模型成功范式启发，无线基础模型（Wireless Foundation Model）成为频谱认知的新路径——在大规模多域射频数据上预训练，再通过轻量迁移适配各类下游识别任务。本文以 LWM-Spectro 为例，系统介绍无线基础模型的信号表征、Transformer 编码器架构、自监督预训练策略和下游迁移学习方法，并基于 38,500 张 OFDM 协议频谱图的仿真验证其性能。我们的实验表明，当我们的任务与预训练的域匹配时，即使我们冻结编码器，模型对于基础协议分类准确率达 99.12%，但是域不匹配（裸调制识别）时调制分类降至 20.8%，而 SNR 回归作为任务通用物理量几乎不受域偏移影响（MAE 1.16 dB）。

关键词：6G；AI 原生网络；频谱认知；无线基础模型；Transformer；迁移学习；LWM-Spectro；OFDM

目录

1	引言	4
1.1	6G 愿景与 AI 原生网络	4
1.2	频谱认知技术的演进	5
1.3	无线基础模型概览	6
1.4	本文组织	6
2	LWM-Spectro 无线基础模型原理	6
2.1	信号的时频表示	6
2.1.1	复基带信号模型	6
2.1.2	数字调制与星座图	7
2.1.3	OFDM 调制原理	7
2.1.4	短时傅里叶变换与频谱图生成	9
2.2	Transformer 编码器架构	9
2.2.1	Patch Embedding	9
2.2.2	多头自注意力	10
2.2.3	位置前馈网络与编码器堆叠	10
2.3	自监督预训练策略	11
2.3.1	掩码频谱图建模 (MSM)	12
2.3.2	对比学习	12
2.4	下游迁移学习	12
2.4.1	分类任务头	12
2.4.2	迁移策略	13
2.5	混合专家 (MoE) 扩展架构	13
3	仿真实验设计	13
3.1	实验目标	14
3.2	编码器加载与验证	14
3.3	数据集: OFDM 协议信号	14
3.3.1	设计原则	14
3.3.2	信号生成流水线	14
3.3.3	数据集统计	15
3.4	频谱图可视化	15
3.5	实验配置	16
4	仿真结果与分析	16
4.1	协议分类性能: 域匹配场景	16
4.1.1	冻结编码器	16
4.1.2	混淆矩阵分析	17

4.1.3	部分微调	18
4.2	域不匹配场景：裸调制信号	19
4.3	SNR 估计：域不匹配下的任务非对称性	19
4.3.1	独立 SNR 回归	19
4.3.2	多任务联合训练的梯度冲突	20
4.4	t-SNE 嵌入可视化	21
4.5	跨域对比总结	21
5	关键技术讨论与工程启示	22
5.1	频谱图生成的工程考量	22
5.2	模型部署的效率分析	23
5.3	域适配的实践建议	23
5.4	从实验室到实际部署的差距	23
6	总结与展望	23
6.1	主要结论	23
6.2	对 6G 频谱认知的启示	24
6.3	未来方向	24
7	附录 A：完整信号生成代码	25
8	附录 B：扩展实验分析	28
8.1	独立 SNR 回归 Per-SNR 误差分解	28
8.2	联合训练的收敛过程	28
8.3	微调训练曲线分析	29
8.4	梯度冲突的定量分析	29
8.5	裸调制微调各类别 F1 分数分析	31
8.6	域不匹配条件下 SNR 回归的额外验证	31

1 引言

1.1 6G 愿景与 AI 原生网络

国际电信联盟（ITU-R）在 IMT-2030 框架中明确了 6G 的六大应用场景，其中”人工智能与通信融合”（AI and Communication Integration）被列为贯穿所有场景的基础性能力 [1]。与 5G 将 AI 作为外挂优化工具不同，6G 提出 AI 原生（AI-Native）的设计范式——AI 能力不再以”外挂”形式附加在通信系统之上，而是从物理层到应用层全栈内嵌。

在 AI 原生范式下，物理层被期望具备对电磁环境的认知能力——判断当前频谱中存在的信号类型、调制方式、干扰源， 并据此自适应调整通信策略。这一能力被称为**频谱认知（Spectrum Cognition）**，是 6G 智能频谱共享、动态频谱接入、抗干扰通信等关键特性的技术前提。图 1 展示了 6G AI 原生通信系统的层级架构，频谱认知位于物理层智能的核心位置， 向上为 MAC 层的自适应编码调制、资源管理层动态频谱接入、应用层的智能服务提供感知输入。




图 1: 6G AI 原生通信系统架构

（频谱认知位于物理层智能的核心，向上支撑资源调度与网络自治）

图 1 五个层级自底向上构成完整的 AI 原生通信栈。**物理层**位于最底层，包含信号检测、信道估计、波束管理等传统功能，是整个系统的感知基底。其中，**频谱认知**横跨物理层与 MAC 层的边界，承担调制识别、协议分类、干扰感知、SNR 估计等功能——这些功能的共同特点是需要从 IQ 采样或频谱图中提取语义级信息（“这是什么信号？”“噪声有多强？”），而非仅完成数学级操作（解调、均衡）。频谱认知的输出向上传递给 **MAC 层**，驱动自适应调制编码（AMC）、智能重传决策等链路适配功能；再向上传递给 **资源管理层**，支撑动态频谱接入（DSA）、频谱共享

和接入控制等网络级网络级决策；最终到达 **应用层**，为智能服务与网络自治提供环境感知上下文。右侧纵贯全栈的 AI 引擎代表内嵌于每一层级的人工智能能力——从物理层的深度学习信号处理到应用层的强化学习资源编排——形成端到端的”感知-决策-执行”闭环。

1.2 频谱认知技术的演进

在一系列的频谱认知任务中，自动调制识别（Automatic Modulation Classification, AMC）是最经典的任务，我们通观对于频谱认知任务的研究，其研究历程清晰地反映了信号处理方法的四代演进。

第一代：似然比方法（1990s–2000s）。基于接收信号的统计特性构建不同调制假设下的似然函数，通过最大似然或平均似然比判决调制类型。在已知信道分布和噪声参数时可达理论最优，但对参数失配极其敏感，计算复杂度随调制阶数指数增长。

第二代：特征工程 + 机器学习（2000s–2010s）。从接收信号中提取人工设计的判别特征——高阶累积量、循环平稳谱特征、瞬时幅度/相位/频率统计量——再送入支持向量机、随机森林等分类器。代表基准数据集 RML2016.10a（11 类调制）推动了标准化评估，典型准确率 80%–90%。但特征设计高度依赖领域专家经验，跨场景泛化能力差。

第三代：端到端深度学习（2010s–2020s）。CNN、ResNet、LSTM 等深度学习模型直接处理 IQ 采样点或星座图，自动学习判别性特征。基于注意力机制的 CNN-Transformer 混合架构在 RadioML 基准上达到 94% 准确率。然而深度模型需要大量标注数据训练，跨信号制式、信道条件的泛化仍不理想。

第四代：无线基础模型（2025–）。大语言模型通过大规模预训练获得通用语言理解能力，再通过微调适配多种下游任务。2025 年以来，研究者将这一“预训练 → 迁移”范式引入无线通信领域，提出了**无线基础模型（Wireless Foundation Model）**：在涵盖多制式、多信道条件下的大规模射频数据上进行自监督预训练，学习通用信号表征，再通过轻量微调适配各类下游识别任务。与传统 AMC 方法相比，基础模型范式的核心优势在于数据效率和跨域泛化——预训练阶段学到的“信号常识”大幅降低了对下游标注数据的需求。

无线基础模型的紧迫性在 6G 动态频谱共享（Dynamic Spectrum Sharing, DSS）场景下尤为突出。传统 AMC 方法面临三重根本性困境：

（1）**特征工程的脆弱性**——手工设计的高阶累积量、循环平稳特征在单一制式、固定信道条件下有效，但一旦进入 6G 预期的多制式共存（5G NR + WiFi + 卫星 + 雷达）、高动态（毫秒级频谱接入切换）、非合作（干扰源制式未知）的频谱环境，人工特征迅速失效；

（2）**模型的不可复用性**——传统“每任务训一个专用模型”的策略意味着每新增一种信号制式或干扰类型，就需要重新采集标注数据、重新训练模型，边际成本恒高；

（3）**标注数据的稀缺性**——实际电磁环境中获取高质量标注数据需要昂贵的测量设备和人工标注，而仿真数据与真实环境之间存在难以跨越的“仿真-真实鸿沟”。

无线基础模型通过“一次预训练、多次轻量适配”的范式，用大规模仿真数据跨越标注瓶颈、用通用表征跨越制式边界，从根本上回应了上述困境。这正是我们选取 LWM-Spectro 进行深入技术介绍的动机。

1.3 无线基础模型概览

2025–2026 年间涌现了多项无线基础模型工作。我们在表 1 列出最具代表性的四者。

表 1：代表性无线基础模型对比

模型	输入	预训练规模	架构	下游任务	开源
RF-GPT[3]	IQ→ 频谱图	62.5 万指令	VLM+LLM	调制/重叠/NR 提取	否
WirelessGPT[4]	信道矩阵	Sionna 仿真	Transformer 三域	信道/预测/感知	否
LWM-Spectro[2]	频谱	920 万张	Transformer+MoE	协议/SNR/移动性	权重 ✓
ContraWiMAE[5]	信道矩阵	跨频段信道	MAE+ 对比	波束/LoS	权重 ✓

由于我们在课上汇报的 RF-GPT 和 WirelessGPT 的模型权重未公开。ContraWiMAE 面向信道级任务，与频谱认知的信号级识别存在模态差异。LWM-Spectro (Kim et al., 2026[2]) 以频谱图为输入模态、以多制式识别为核心能力，与 6G 频谱认知的技术需求高度契合，且模型权重在 HuggingFace 上完全开源 (wi-lab/lwm-spectro)。因此，本文选取 LWM-Spectro 作为技术介绍的实例。

1.4 本文组织

我们将以技术介绍为主线：在第二章我们将完整推导 LWM-Spectro 的核心原理；在第三章，我们下载了 LWM-Spectro 的相关权重，构建一系列仿真数据，尝试对进行微调；第四章，我们将呈现仿真结果，并综合分析其性能；第五章，我们讨论工程实现要点与部署考量；第六章，我们将对这项技术进行总结与展望。

2 LWM-Spectro 无线基础模型原理

2.1 信号的时频表示

2.1.1 复基带信号模型

现代数字通信系统中，接收端复基带采样信号可建模为：

$$y[n] = \sum_{l=0}^{L-1} h_l[n] \cdot x[n-l] + w[n] \quad (1)$$

其中 $x[n]$ 为发送的复基带符号序列， $h_l[n]$ 为第 l 条路径的时变复信道增益， L 为多径数量， $w[n] \sim \text{CN}(0, \sigma_w^2)$ 为复加性高斯白噪声。信噪比定义为：

$$\text{SNR}_{\text{dB}} = 10 \cdot \log_{10} \frac{\mathbb{E}[|x[n]|^2]}{\sigma_w^2} \quad (2)$$

本文实验采用简化的 AWGN 平坦信道 ($L = 1, h_0 = 1$) : $y[n] = x[n] + w[n]$ 。

2.1.2 数字调制与星座图

对于 M-QAM，发送符号的星座点集合为：

$$\mathcal{C}_M = \left\{ \frac{a + jb}{\sqrt{E_M}} \mid a, b \in \{\pm 1, \pm 3, \dots, \pm(\sqrt{M} - 1)\} \right\} \quad (3)$$

归一化因子 $E_M = 2(M - 1)/3$ 使 $\mathbb{E}[|x[n]|^2] = 1$ 。常用调制阶数包括 BPSK ($M = 2$)、QPSK ($M = 4$)、16QAM ($M = 16$)、64QAM ($M = 64$) 和 256QAM ($M = 256$)。

为限制信号带宽并消除符号间干扰 (ISI)，发送端采用根升余弦 (RRC) 滤波器，时域冲激响应为：

$$h_{\text{RRC}}(t) = \frac{\sin\left(\frac{\pi t}{T_s}(1 - \beta)\right) + 4\beta \frac{t}{T_s} \cos\left(\frac{\pi t}{T_s}(1 + \beta)\right)}{\frac{\pi t}{T_s} [1 - (4\beta \frac{t}{T_s})^2]} \quad (4)$$

其中 $\beta \in [0, 1]$ 为滚降系数 (本文取 $\beta = 0.35$)。图 2 展示了五种调制方式的星座图。




图 2: 数字调制星座图

(从 BPSK (2 点) 到 256QAM (256 点)，随阶数增加星座密度指数增长，噪声容限急剧缩小)

2.1.3 OFDM 调制原理

正交频分复用 (OFDM) 是 WiFi、LTE、5G NR 共同的物理层核心技术。其基本原理是将高速串行数据流分解为 N_{sc} 路并行的低速子载波，每路子载波采用独立的窄带调制。

第 m 个 OFDM 符号的频域向量记为 $X_m \in \mathbb{C}^{N_{\text{sc}}}$ ，其元素按功能分为三类：数据子载波 (承载 QAM 调制符号，位置 D)、导频子载波 (承载固定参考信号，位置 P)、保护子载波 (置零，分布于频带边缘)。为保证 IFFT 输出为实基带信号，频域向量需满足 Hermitian 对称性：

$$X_m[N_{sc} - k] = X_m^*[k], \quad k = 1, \dots, N_{sc}/2 - 1 \quad (5)$$

频域向量经 N_{sc} 点 IFFT 变换到时域：

$$x_m[n] = \frac{1}{\sqrt{N_{sc}}} \sum_{k=0}^{N_{sc}-1} X_m[k] \cdot e^{j2\pi kn/N_{sc}}, \quad n = 0, \dots, N_{sc} - 1 \quad (6)$$

为对抗多径时延扩展，每个 OFDM 符号前添加循环前缀（CP），将符号末尾 N_{cp} 个采样点复制到符号前端：

$$x_m^{CP}[n] = \begin{cases} x_m[N_{sc} - N_{cp} + n], & 0 \leq n < N_{cp} \\ x_m[n - N_{cp}], & N_{cp} \leq n < N_{sc} + N_{cp} \end{cases} \quad (7)$$

M 个 OFDM 符号（含 CP）级联构成一个完整的传输帧。图 3 展示了 OFDM 信号生成与频谱图转换的完整处理流程。




图 3: OFDM 信号生成全流程

（比特 → 符号映射 → 子载波分配 → IFFT → 加CP → 信道 → STFT → 频谱图）

本文模拟了三种 OFDM 协议的关键参数差异（见表 2）。三种协议的子载波总数差异（64/128/256）在频谱图上形成直观可辨的子载波密度梯度，CP 长度的差异影响符号边界在时间轴上的间隔，导频密度的差异产生不同疏密的频率轴周期性图案——这些差异是协议分类的物理基础。

表 2: 三种 OFDM 协议的参数配置

参数	WiFi 风格	LTE 风格	5G NR 风格
子载波总数 N_{sc}	64	128	256
数据子载波数	48	100	200
导频子载波数	4（固定位置）	12（等间距）	20（等间距）
CP 长度 N_{cp}	16	32	32
每帧 OFDM 符号数	12	8	5
支持调制阶数	2/4/16/64	4/16/64	4/16/64/256

2.1.4 短时傅里叶变换与频谱图生成

接收信号 $y[n]$ 的时频表示通过短时傅里叶变换（STFT）获得。STFT 将一维时间序列映射为二维时频谱：

$$\text{STFT}\{y\}(m, k) = \sum_{n=0}^{N_w-1} y[n + mR] \cdot w[n] \cdot e^{-j2\pi kn/N_{\text{FFT}}} \quad (8)$$

各参数： $w[n]$ 为 Hann 窗， $N_w = N_{\text{FFT}} = 128$ ，hop size $R = 16$ 。STFT 输出复值矩阵，取幅值后进行三步后处理：(1) 截取/填充至 128×128 ；(2) 对数压缩： $S_{\log}[m, k] = \log(1 + |\text{STFT}(m, k)|)$ ；(3) Min-Max 归一化到 $[0, 1]$ 。图 4 展示了同一 OFDM 信号的时域、频域和频谱图三种表示。




图 4: 同一 OFDM 信号的三视图

（上： 时域 IQ 波形；中：功率谱密度；下 STFT 频谱图）

2.2 Transformer 编码器架构

LWM-Spectro 采用 12 层 Transformer 编码器 [6] 作为骨干网络。

2.2.1 Patch Embedding

128×128 频谱图被划分为不重叠的 4×4 小块，共 $(128/4) \times (128/4) = 1024$ 个 patch。每 patch 16 维经线性投影映射到 $d_{\text{model}} = 128$ 维，加可学习位置编码：

$$z_i^{(0)} = W_p \cdot \text{vec}(\text{patch}_i) + b_p + p_i, \quad i = 1, 2, \dots, 1024 \quad (9)$$

其中 $W_p \in \mathbb{R}^{128 \times 16}$ 为投影矩阵， $p_i \in \mathbb{R}^{128}$ 为位置嵌入。图 5 示意了这一过程。




图 5: Patch Embedding:

(128×128 频谱图 → 1024 个 4×4 patch → 1024个128维token)

选取 4×4 patch 大小（远小于 ViT 在自然图像中常用的 16×16 ）是出于频谱图的特殊结构考量。 128×128 的 OFDM 频谱图中，子载波线间距在频率轴上约为 2–4 个像素，CP 边界在时间轴上的间隔约为 8–16 个像素。 4×4 的 patch 恰好能够捕捉到单个子载波线内的局部纹理变化，同时 1024 的序列长度在 Transformer 自注意力的二次复杂度下仍可承受。若采用更大的 patch（如 8×8 ），序列长度降至 256，计算更快但会丢失子载波级的精细频率结构；若采用更小的 patch（如 2×2 ），序列长度增至 4096，自注意力计算开销过大。 4×4 是在分辨率和计算效率之间的经验最优折中。

2.2.2 多头自注意力

对于第 ℓ 层的输入 $Z^{(\ell-1)} \in \mathbb{R}^{1024 \times 128}$ ，首先计算查询、键和值投影：

$$Q_h = Z^{(\ell-1)} W_h^Q, \quad K_h = Z^{(\ell-1)} W_h^K, \quad V_h = Z^{(\ell-1)} W_h^V \quad (10)$$

其中 $W_h^Q, W_h^K, W_h^V \in \mathbb{R}^{128 \times d_k}$ ， $H = 8$ 个注意力头，每头维度 $d_k = 128/8 = 16$ 。第 h 个注意力头的输出由 Scaled Dot-Product Attention 计算：

$$\text{head}_h = \text{softmax}\left(\frac{Q_h K_h^T}{\sqrt{d_k}}\right) V_h \quad (11)$$

除以 $\sqrt{d_k} = 4$ 防止内积过大导致 softmax 梯度消失。H 个头拼接后经线性投影：

$$\text{MSA}(Z) = \text{Concat}(\text{head}_1, \dots, \text{head}_H) W^O \quad (12)$$

MSA 子层输出经残差连接和层归一化： $Z_{\text{attn}}^{(\ell)} = \text{LayerNorm}(Z^{(\ell-1)} + \text{MSA}(Z^{(\ell-1)}))$ 。

2.2.3 位置前馈网络与编码器堆叠

FFN 子层对每个位置独立施加两层全连接变换： $\text{FFN}(z_i) = \max(0, z_i W_1 + b_1) W_2 + b_2$ ，其中 $W_1 \in \mathbb{R}^{128 \times 512}$ ， $W_2 \in \mathbb{R}^{512 \times 128}$ 。FFN 同样经残差连接和层归一化。

LWM-Spectro 堆叠 $L = 12$ 层编码器。最终输出 $Z^{(12)} \in \mathbb{R}^{1024 \times 128}$ 经全局平均池化得到固定长度的信号表征向量 $\mathbf{f} = \frac{1}{1024} \sum_{i=1}^{1024} \mathbf{z}_i^{(12)} \in \mathbb{R}^{128}$ 。图 6 展示了完整的编码器架构。




图 6: LWM-Spectro 编码器架构

(12 层 Transformer Encoder , d = 128 , 8 头自注意力, 全局池化输出 128 维表征)

表 3: LWM-Spectro 编码器参数量统计

组件	参数量	占比
Patch Embedding (proj + pos embedding)	133,248	5.1%
12 层 Transformer Encoder (MSA + FFN + LayerNorm × 12)	2,492,160	94.7%
解码器 (decoder linear + bias)	5,779	0.2%
总计	2,631,187	100%

2.3 自监督预训练策略

LWM-Spectro 的预训练不依赖任何人工标注, 通过两种自监督任务学习通用频谱图表征。

2.3.1 掩码频谱图建模 (MSM)

MSM 受 BERT[7] 和 MAE[8] 启发。在每一轮训练中随机遮蔽 70% 的输入 patch ($|\mathcal{M}| \approx 717$)，要求模型仅从剩余 30% 可见 patch 中重建被遮蔽 patch 的原始嵌入：

$$\mathcal{L}_{\text{MSM}} = \frac{1}{|\mathcal{M}|} \sum_{i \in \mathcal{M}} \|\hat{\mathbf{x}}_i - \mathbf{x}_i\|_2^2 \quad (13)$$

高掩码率 (70%) 迫使编码器从有限的可见上下文推理全局时频结构。图 7 展示了 MSM 的遮蔽与重建流程。




图 7: MSM 预训练: (a) 原始频谱图; (b) 70% patch 遮蔽; (c) 编码器处理可见 patch; (d) 重建整张频谱图

2.3.2 对比学习

联合训练阶段加入 InfoNCE 对比损失 [9]，鼓励同类信号的编码器表征相互靠近、异类表征相互远离：

$$\mathcal{L}_{\text{contrast}} = -\frac{1}{B} \sum_{i=1}^B \log \frac{\exp(\mathbf{f}_i \cdot \mathbf{f}_i^+ / \tau)}{\sum_{j=1, j \neq i}^B \exp(\mathbf{f}_i \cdot \mathbf{f}_j / \tau)} \quad (14)$$

其中 $\mathbf{f}_i$ 为样本 i 的编码器输出表征， $\mathbf{f}_i^+$ 为同类正样本表征， τ 为温度参数。最终预训练损失为 $\mathcal{L}_{\text{pretrain}} = \mathcal{L}_{\text{MSM}} + \lambda \mathcal{L}_{\text{contrast}}$ 。

LWM-Spectro 的预训练数据集包含 920 万张频谱图，覆盖 3 种通信制式 (WiFi、LTE、5G NR)、20 个城市信道环境 (基于 DeepMIMO 射线追踪数据集 [10])、-5 至 +25 dB 的 SNR 范围，以及多种移动速度条件。

2.4 下游迁移学习

预训练完成后，编码器可被视为“频谱图特征提取器”。下游任务适配仅需在编码器之上添加轻量任务头。

2.4.1 分类任务头

编码器输出 $\mathbf{Z}^{(12)} \in \mathbb{R}^{1024 \times 128}$ 转置为 $\mathbb{R}^{128 \times 1024}$ ，送入两层残差 1D 卷积：

$$\mathbf{H} = \text{ReLU}\left(\text{BN}\left(\text{Conv1d}_{128 \rightarrow 128}(\mathbf{Z}^{(12)T})\right)\right) \quad (15)$$

$$\mathbf{H}' = \text{ReLU}\left(\text{BN}(\text{Conv1d}_{128 \rightarrow 128}(\mathbf{H}))\right) \quad (16)$$

$$\mathbf{g} = \frac{1}{1024} \sum_{t=1}^{1024} \mathbf{H}'_{:,t} \in \mathbb{R}^{128} \quad (17)$$

$$\hat{\mathbf{y}} = \text{softmax}(\mathbf{W}_c \mathbf{g} + \mathbf{b}_c) \quad (18)$$

其中 C 为类别数。分类头总参数量约 100K。

2.4.2 迁移策略

我们对比两种迁移策略：**策略 A（冻结编码器）**——编码器全部参数冻结，仅训练分类头，可训练参数约 100K，学习率 10^{-3} ，适用于域匹配场景；**策略 B（部分微调）**——仅解冻最后 2 层 Transformer 参数，可训练参数约 496K，学习率 10^{-5} ，适用于域轻微偏移场景。

2.5 混合专家（MoE）扩展架构

LWM-Spectro 的完整预训练模型在单一编码器之上引入了混合专家架构，这是其区别于其他无线基础模型（如 WirelessGPT、ContraWiMAE）的特色设计。本节简要介绍其核心思想，以完整呈现 LWM-Spectro 的技术全景。本文实验仅使用单一 5G Expert 的编码器权重，MoE 的完整训练与路由机制未经实验验证。

设计动机。 WiFi、LTE、5G NR 三制式的频谱图在子载波密度（64→256）、CP 长度（16→32）和导频图案上差异显著，单一编码器可能难以在所有制式上同时达到最优。MoE 将“通用编码”分解为三个协议专用 Expert 编码器（各约 2.6M 参数），一个轻量 CNN Router（约 50K 参数，结构为 Conv2d(1,32)→Conv2d(32,64)→Conv2d(64,128)→GAP→Linear(1) 根据输入频谱图选择激活哪个 Expert。

Top-1 路由推理： 输入频谱图 S 送入 Router 计算路由概率 $p = \text{softmax}(\text{Router}(S))$ ，选择 $k^* = \arg \max_k p_k$ ，仅激活 Expert_{k^*} 进行前向传播。尽管存储三个 Expert（~7.9M 参数），每次推理仅 ~2.6M 参数参与计算。

本文使用策略： 直接使用 5G Expert 编码器权重，绕过 Router。理由为：（1）三 Expert 结构一致，差异仅在预训练数据分布；（2）5G NR 是 6G 演进的前身技术，与 6G 候选波形最接近；（3）绕过 Router 使实验结果纯粹反映编码器表征质量，不受路由不确定性干扰。

3 仿真实验设计

3.1 实验目标

仿真实验围绕递进目标设计：(1) 验证 LWM-Spectro 编码器能否直接用于 OFDM 协议信号分类；(2) 评估不同 SNR 条件下识别性能的鲁棒性；(3) 对比冻结编码器与部分微调的性能差异；(4) 在域不匹配（裸调制信号）条件下量化性能退化程度；(5) 探索 SNR 回归作为任务无关物理量的域偏移鲁棒性。

3.2 编码器加载与验证

从 LWM-Spectro 开源 MoE checkpoint (moe_checkpoint.pth, 30.2 MB) 中提取 5G Expert 的编码器权重。权重加载时需去除 model.backbone. 前缀。经验证：0 缺失键，0 意外键，2,631,187 个参数全部成功匹配。

Listing 1: 编码器权重加载 (Python/PyTorch)

```
1 ckpt = torch.load("moe_checkpoint.pth", map_location='cpu')
2 sd = ckpt['expert_state_dicts'][2]['state_dict'] # 5G expert
3 new_sd = {k[15:]: v for k, v in sd.items()}
4         if k.startswith('model.backbone.')}
5 encoder = LWM(element_length=16, d_model=128, n_layers=12,
6             n_heads=8, dropout=0.1, max_len=1025)
7 encoder.load_state_dict(new_sd, strict=False) # 0 missing, 0
            unexpected
```

3.3 数据集：OFDM 协议信号

3.3.1 设计原则

实验数据集需满足：(1) 信号结构贴近 LWM-Spectro 预训练数据——具有 OFDM 结构特征（子载波、CP、导频）；(2) 三种协议参数差异在频谱图上形成可辨识的纹理差异，使协议分类成为有意义的任务。

3.3.2 信号生成流水线

每张频谱图经历 7 个步骤：比特生成 → QAM 符号映射 → 子载波分配 → IFFT → 加 CP → 多符号级联 → AWGN 加噪 → STFT → 频谱图。流程图见第 2.1.3 节图 3。所有信号生成采用纯 Python (NumPy/SciPy)。同步生成对照数据集：裸基带调制信号（BPSK/QPSK/16QAM/64QAM/256QAM × 7 SNR × 1000 样本 = 35,000 张），用于量化域不匹配的性能退化。

3.3.3 数据集统计

表 4: OFDM 协议信号数据集统计

参数	值
协议类型调制类型 SNR	WiFi (4 调制)、LTE (3 调制)、5G (4 调制) BPSK/QPSK/16QAM/64QAM/256QAM
范围	-5, 0, +5, +10, +15, +20, +25 dB (7 档)
每 (协议, 调制, SNR) 样本数	500
总样本数	38,500
频谱图尺寸	128×128, float32, 值域 [0, 1]
数据划分	70% 训练 / 15% 验证 / 15% 测试

3.4 频谱图可视化

图 8 展示了三种协议在不同调制和 SNR 下的频谱图样本。子载波栅格（水平亮线）、CP 边界（垂直暗带）和导频亮斑清晰可见。图 9 将裸调制和 OFDM 信号频谱图并列展示，两者在视觉结构上的差异一目了然。




图 8: OFDM 协议频谱图示例矩阵

(行对应协议 (WiFi/LTE/5G), 列对应调制类型, SNR=20dB。子载波密度差异 (64→ 128→ 256))




图 9: 裸调制（上行）与 OFDM 协议（下行）频谱图对比。
（裸调制频谱图缺乏 OFDM 的格子状结构化纹理，呈现连续谱特征）

3.5 实验配置

表 5: 训练超参数

超参数	冻结（OFDM）	部分微调（OFDM）	冻结（裸调制）	全微调（裸调制）
学习率	10^{-3}	10^{-5}	10^{-3}	10^{-5}
优化器	AdamW	AdamW	AdamW	AdamW
权重衰减	10^{-4}	10^{-4}	10^{-4}	10^{-4}
调度器	CosineAnnealing	CosineAnnealing	CosineAnnealing	CosineAnnealing
Epochs	8	4	50	50
Batch Size	12	12	32	128
可训练参数	~100K	~496K	~100K	~2.6M

实验硬件：Intel Core i7 + NVIDIA RTX 4060（8 GB，OFDM 实验） / 8 × RTX 4090（服务器，裸调制实验）。软件：Python 3.10 + PyTorch 2.10 + CUDA 12.6。

4 仿真结果与分析

4.1 协议分类性能：域匹配场景

4.1.1 冻结编码器

我们在 OFDM 协议信号数据集上，冻结 LWM-Spectro 编码器仅训练分类头即取得了优异的协议三分类性能。表 6 汇总了关键指标。

表 6: 冻结编码器协议分类结果

指标	值
测试集总体准确率	99.12%
最佳验证准确率	98.75% (Epoch 5)
收敛速度	Epoch 1 验证准确率 96.38%
-5 dB 准确率	93.60%
≥ 0 dB 准确率	100.00%

即便在极低 SNR（-5 dB，噪声功率是信号功率的 3.16 倍）下，准确率仍保持 93.6%。这归功于 OFDM 的结构化冗余——子载波等间距排列、导频周期性重复、CP 造成的清晰符号边界——Transformer 的自注意力机制天然适合捕获此类全局模式。图 10对比了冻结与微调策略的 Per-SNR 准确率曲线。




图 10: 冻结编码器与部分微调的 Per-SNR 准确率曲线

（冻结方案在 SNR ≥ 0 dB 测试条件下准确率达到 100%，微调方案在低 SNR 下反而下降）

4.1.2 混淆矩阵分析

表 7 给出了冻结编码器的混淆矩阵。唯一的薄弱点在 LTE 与 5G 之间（41 个 LTE 样本误判为 5G），可追溯至两者在 CP 长度（均为 32）上的完全一致，仅靠子载波密度（128 vs 256）区分。图 11 以热力图形式比较了冻结与微调的混淆矩阵。




图 11: 混淆矩阵对比

(冻结 (左) 仅 LTE与5G 轻微混淆; 微调 (右) 出现LTE→ WiFi 和 5G→ WiFi 的新误判)

表 7: 冻结编码器混淆矩阵

	预测 WiFi	预测 LTE	预测 5G
实际 WiFi	2,091	3	6
实际 LTE	0	1,534	41
实际 5G	0	1	2,099

4.1.3 部分微调

解冻编码器最后 2 层并以 10^{-5} 学习率微调后，测试准确率降至 94.65%，低于冻结方案的 99.12%。微调导致系统性退化，退化在低 SNR 下尤为严重——-5 dB 准确率从 93.6% 暴跌至 63.0%。微调混淆矩阵显示 LTE 和 5G 样本被大量误判为 WiFi（分别为 146 例和 89 例），说明在有限梯度信号下产生了不稳定的权重更新方向。表8汇总了两种策略的对比。

表 8: 部分微调 vs 冻结编码器对比

指标	冻结编码器	部分微调
测试准确率	99.12%	94.65%
-5 dB 准确率	93.60%	63.03%
0 dB 准确率	100.0%	98.36%
≥ 5 dB 准确率	100.0%	100.0%

为什么在我们进行微调后，反而导致了性能退化？这一反直觉现象可从优化景观（Loss Landscape）角度加以理解。即预训练编码器的权重位于一个宽阔、平坦的最优点——该点对 OFDM 协议分类具有高准确率和强泛化性。当以极低学习率（ 10^{-5} ）在有限的 OFDM 数据（38,500 样本）

上微调最后两层时，优化器沿着验证损失曲面中的窄谷方向移动了权重，使其偏离了预训练的最优平坦区域。在高 SNR (≥ 5 dB) 条件下，移动后的权重仍能维持 100% 准确率——说明特征空间的全局拓扑未被破坏。但在低 SNR (-5 dB) 条件下，微调后的权重对噪声的鲁棒性急剧下降 ($93.6\% \rightarrow 63.0\%$)——说明微调主要破坏的是编码器对弱信号的”边缘决策边界”，而非对强信号的”核心决策区域”。这一现象与 Li 等人 (2018) 关于”预训练宽最优解的脆弱性”的发现一致：即使极小幅度的微调也可能使权重跳出平坦最优区，进入一个训练损失更低但在分布外样本上泛化更差的尖锐局部极小。

4.2 域不匹配场景：裸调制信号

为验证预训练域与下游域匹配度对迁移性能的影响，我们在裸基带调制信号上进行了对照实验。裸调制信号不含 OFDM 结构——没有子载波、没有循环前缀、没有导频，这三点恰恰是 LWM-Spectro 在预训练阶段最依赖的时频纹理特征。表 9 汇总了结果。

表 9: 域不匹配（裸调制）的调制分类结果

	冻结编码器	全参数微调
总体准确率	20.80%	39.50%
BPSK		99.0%
64QAM		95.0%
QPSK		3.0%
16QAM		0.0%
256QAM		0.0%

可以发现，冻结编码器准确率 20.80%，接近 5 类均匀随机猜测水平（20%）。这是因为编码器从未在预训练中见过不含 OFDM 结构的单载波频谱图，其 128 维输出表征对调制阶数几乎是正交的。而全参数微调将准确率提升至 39.50%，但性能呈现极端的类间不均衡——BPSK（99%）和 64QAM（95%）表现优异，而 QPSK（3%）、16QAM（0%）、256QAM（0%）完全失效。之所以会出现这样的两极分化，我们猜测，可能是 BPSK 和 64QAM 分别在频谱图上产生”相位翻转条纹”与”均匀噪声填充”两种极端纹理，编码器的浅层滤波器对这两类极性差异偶然敏感；但是对于 QPSK/16QAM/256QAM 沿”稀疏 $\rightarrow$ 稠密”连续谱分布，编码器未学会沿此维度判别，导致准确率骤降。

4.3 SNR 估计：域不匹配下的任务非对称性

前面的调制分类实验表明，一旦输入信号脱离 OFDM 结构，编码器几乎完全失效。但这是否意味着编码器在域不匹配条件下就毫无用处？我们注意到一个关键区别：调制分类需要识别信号的”内部结构”（星座点排布、子载波排列），而 SNR 估计只需要

回答一个更基本的问题——“信号有多强、噪声有多大”。后者不关心信号长什么样，只关心全局的功率比例。

4.3.1 独立 SNR 回归

我们在裸调制数据集上做了如下实验：冻结编码器，在它上面接一个最简单的回归头（单层线性映射，128维输入→1维输出，预测一个dB值），用均方误差损失训练。测试结果：平均绝对误差1.16 dB，均方根误差1.57 dB。图12展示了预测值与真实SNR的散点

图 12 展示了预测值与真实 SNR 的散点图。




图 12: SNR 回归散点图

(预测值接近对角线（理想估计），中间 SNR 区（10 - 15 dB）偏差略大）

对比同一数据集上调制分类20.80%的准确率,SNR回归之所以有效，是因为编码器不需要看懂频谱图上的精细纹理——它只需要感知图像整体的“亮度”。信噪比越高，频谱图上信号成分越亮、噪底越暗；信噪比越低，整张图越趋于均匀的灰色。这种“整体明暗”信息在编码器的128维输出中必然占据某几个维度，与频谱图的具体纹理无关。LWM-Spectro在预训练阶段接触过920万张覆盖-5到+25 dB的频谱图，编码器早已学会稳定地编码信号强度信息。

4.3.2 多任务联合训练的梯度冲突

在实际应用中，我们可能希望一个模型同时完成调制分类和SNR估计两项任务。我们在裸调制数据上尝试了这种联合训练。表 10 汇总了三种联合训练配置的结果。

表 10: 多任务联合训练结果（裸调制数据）

配置	调制准确率	SNR MAE	说明
独立训练（调制）	39.50%	—	单任务上限
独立训练（SNR）	—	1.16 dB	单任务上限
Joint 15 epoch	28.7%	7.36 dB	SNR 权重 0.1，梯度冲突
Joint Full 50 epoch	29.4%	2.78 dB	增加 epoch 后 SNR 改善
Joint v2	37.3%	1.60 dB	加深分类头 + 调权重

我们发现，Joint（15 epoch）的 SNR MAE 从独立训练的 1.16 dB 暴增至 7.36 dB，几乎随机猜测水平——问题出在两个任务的优化方向上存在冲突：SNR 回归的梯度希望编码器保留全局功率信息，而调制分类的梯度希望编码器放大频谱纹理的细微差异。在域不匹配条件下，后者的梯度信号本身就带着大量噪声，两者叠加后共享编码器的权重在两个目标之间来回震荡，哪个都收敛不好。后来，我们通过加深分类头（128→256→128→64→5）和调整 SNR 损失权重，Joint v2 将调制准确率恢复至接近独立水平（37.3% vs 39.5%）。

4.4 t-SNE 嵌入可视化

图 13 展示了编码器输出表征的 t-SNE 降维结果。在域匹配（OFDM 协议）条件下，三类协议形成边界清晰的簇；在域不匹配（裸调制）条件下，五类调制几乎完全重叠，仅 BPSK 勉强分离。




图 13: t-SNE 嵌入可视化对比

（域不匹配（裸调制），调制类别高度重叠）

4.5 跨域对比总结

表 11 汇总了全部实验结果。

表 11: 实验结果全景

	域匹配（OFDM 协议）	域不匹配（裸调制）
调制/协议分类——冻结	99.12%	20.80%
调制/协议分类——微调	94.65%	39.50%
SNR 回归——冻结	—	MAE 1.16 dB
联合训练（最佳）	—	Mod 37.3%, SNR 1.60 dB

核心发现 1：域匹配度是第一位的因素。域匹配时的冻结方案（99.12%）远超域不匹配时的最优微调方案（39.50%），差距约 60 个百分点。

核心发现 2：域不匹配对不同任务的打击是非对称的——调制分类需要结构化纹理（基本失效），SNR 回归仅需全局功率统计（几乎不受影响）。

核心发现 3：域匹配时微调不必要且有害（99.12%→94.65%）。

核心发现 4：多任务联合训练在域不匹配时面临严重的梯度冲突。

图 14 以更精细的视角展示了域匹配条件下 OFDM 协议三类样本的 t-SNE 嵌入分布。




图 14: 域匹配（OFDM 协议）t-SNE 嵌入

（WiFi、LTE、5G 三类形成边界清晰的嵌入簇）

5 关键技术讨论

5.1 频谱图生成

STFT 窗函数与参数选择对性能至关重要。我们采用Hann窗而非矩形窗，原因是Hann窗的旁瓣抑制能力更强——OFDM信号的相邻子载波在频谱图上间距仅几个像素，旁瓣泄漏会导致子载波边界模糊，而Hann窗能有效减轻这一问题。其中对于 $N_{\text{FFT}} = 128$ 和 $R = 16$ 的参数选择，我们认为此时才能在频率分辨时间分辨率之间取得平衡。最后，我们采用了输入信号进行对数压缩，由于原始频谱图的动态范围可达60 dB以上（信号尖峰与噪底之间的功率差），直接输入神经网络会导致梯度集中在少数高激活区域。经 $\log(1 + |\text{STFT}|)$ 压缩后，动态范围被映射到紧凑区间，更利于训练稳定。Per-sample Min-Max 归一化使每个样本独立归一化，让模型在推理时无需维护全局统计量。

5.2 模型部署的效率分析

LWM-Spectro 编码器在计算效率上具有显著优势。

表 12: 模型效率对比

指标	LWM-Spectro	ResNet-18	ViT-B/16
参数量	2.6M	11.2M	86.6M
单张推理耗时（RTX 4060）	~15 ms	~8 ms	~40 ms
部署内存（FP32）	~10 MB	~45 MB	~346 MB

2.6M 的极低参数量使 LWM-Spectro 即便在边缘设备上部署也不存在显著的算力障碍。推理时仅需编码器 + 分类头，前向过程包含 12 层 $\text{Transformer} \times 1024$ 序列 $\times 128$ 维的 MSA 和 FFN 计算，单张推理约 15 ms。

5.3 从实验室到实际部署的差距

本文的实验环境与实际部署之间存在几项差距需要正视。

信道建模方面，本文与LWM-Spectro预训练均采用AWGN平坦信道（单径、无衰落）。实际无线环境中，多径衰落和多普勒扩展是普遍存在的，它们会显著改变频谱图的时频纹理——多径引入频率选择性凹陷，多普勒导致子载波在时间轴上扩散。编码器是否能在这些失真下保持表征质量，本文未做验证。

噪声模型方面，仿真中使用的加性高斯白噪声假设了平坦功率谱和独立同分布，而真实电磁环境中的噪声往往是非平坦的（例如邻近频段的干扰在频谱图上形成局部高亮区），且存在突发性干扰。这些噪声形态在预训练数据中未覆盖，可能成为域偏移的额外来源。

此外，本文所有实验均为单信号场景，而实际频谱认知常需面对多信号共存的盲分离需求——多张频谱图叠加、不同信号互相遮蔽，问题复杂度远高于单信号分类。

6 总结与展望

6.1 主要结论

本文以LWM-Spectro为实例，对面向6G的AI原生频谱认知技术进行了系统介绍与实验验证。

在原理层面，我们完整推导了从复基带信号模型、OFDM调制、STFT时频变换，到Transformer编码器的Patch Embedding、多头自注意力、位置前馈网络，以及掩码频谱图建模与对比学习自监督预训练策略的全链路技术体系。在此基础上，我们进一步介绍了LWM-Spectro区别于同期无线基础模型的混合专家扩展架构。

在实验层面，我们从开源MoE checkpoint中提取了5G Expert编码器权重，构建了包含38,500张OFDM协议频谱图的数据集（WiFi/LTE/5G NR三种协议，7档SNR，多调制阶数），并同步生成了35,000张裸调制频谱图作为域不匹配对照集。基于这些数据，我们完成了四组实验：

（1）**预训练域匹配条件下的协议分类**。冻结编码器仅训练分类头，测试准确率达到99.12%，全SNR范围表现良好（ -5 dB时93.60%， ≥ 0 dB时100%）。

（2）**迁移策略对比**。部分微调（解冻最后两层）的测试准确率为94.65%，低于冻结方案，且在 -5 dB条件下降至63.03%。有限数据上的微调未能改善性能，反而破坏了预训练权重的泛化性质。

（3）**预训练域不匹配条件下的调制分类**。在裸调制频谱图上，冻结编码器准确率降至20.80%（接近五分类随机水平），全参数微调后提升至39.50%，但类间表现极不均衡——BPSK和64QAM的F1分数超过90%，QPSK、16QAM、256QAM几乎完全失效。

（4）**SNR回归的域偏移鲁棒性**。同样在域不匹配条件下，冻结编码器配合单值回归头达到MAE 1.16 dB的SNR估计精度，与同期调制分类的失效形成鲜明反差。此外，在多任务联合训练中，我们观察到了调制分类与SNR回归之间的梯度冲突现象——两种任务的梯度方向余弦相似度持续为负值，SNR回归的MAE从独立训练的1.16 dB暴增至联合训练的7.36 dB。通过加深分类头并调整损失权重，两任务分别恢复至37.3%和1.60 dB，接近各自独立训练水平。

6.2 对 6G 频谱认知的启示

无线基础模型为 6G 频谱认知提供了一条不同于“每任务专用模型”的技术路线。其核心价值不在于特定任务上的绝对性能（传统 AMC 亦可达 90%+），而在于**通用性**——单一预训练编码器可支撑多种下游频谱认知任务，大幅降低标注数据需求和模型开发成本。

通过本次仿真实验，我们可以得到如下启示：(1) **数据优先于算法**——将下游信号生成参数（子载波数、CP 长度、导频结构）对齐预训练域，可带来约 78 个百分点的性能提升，远超任何微调策略可带来的改进（通常不足 20 个百分点）；(2) **简单优于复杂**——域匹配时冻结编码器 + 线性分类头（约 100K 可训练参数）优于有 496K 可训练参数的部分微调，简单方案不仅训练更快、部署更轻，而且泛化更稳定；(3) **任务特性决定迁移难度**——全局物理量（如 SNR）的迁移远比结构化纹理识别（如调制分类）更容易，这为 6G 频谱认知系统的任务优先级排序提供了依据。

6G 需要处理比 5G 更异构、更动态的频谱环境——毫米波与太赫兹频段、非授权频谱共享、通感一体化（ISAC）、动态频谱接入——每种场景都需要对频谱环境进行实时认知。传统“每场景训一个专用模型”的策略在部署成本和维护复杂性上不可持续。预训练基础模型 + 轻量任务适配的范式提供了一条更经济、更可扩展的技术路径：在端侧部署一个约 10 MB 的编码器，通过简单的分类头适配即可覆盖频谱监测、干扰识别、信号解调等多种认知功能。

6.3 技术不足

通过本次实验，我们也注意到 LWM-Spectro 在当前阶段存在几项不足。

域绑定过强。这是本次实验最突出的发现。LWM-Spectro 的预训练数据以 OFDM 体系信号为主，编码器习得的表征空间与子载波栅格、CP 边界、导频图案等 OFDM 特有纹理高度绑定。当输入信号的时频结构脱离这一体系（如裸调制），表征的判别能力迅速失效。从技术角度看，这意味着当前版本的 LWM-Spectro 更接近一个“OFDM 专家”而非“通用频谱基础模型”——它在 OFDM 域内确实能泛化到不同协议，但尚未具备跨信号体系的泛化能力。

跨任务泛化不均衡。实验显示，编码器对不同层次物理量的编码鲁棒性差异显著。全局功率统计（SNR）的编码几乎不受域偏移影响，而调制阶数、星座排布等精细纹理的判别高度依赖域匹配。这表明编码器内部尚未形成对信号结构的层次化解耦表征——哪些维度编码“信号有多强”、哪些维度编码“信号长什么样”，目前是隐式混合的，缺乏显式分离。由此带来的后果是多任务联合训练时出现梯度冲突——两个任务对共享表征的需求互相竞争，各任务性能均低于独立训练。

预训练覆盖范围有限。当前预训练数据在信道条件（AWGN 平坦信道为主）、噪声模型（高斯白噪声）、信号制式（WiFi/LTE/5G NR 均属 OFDM 体系）三个维度上的覆盖偏窄。第 5.3 节已经讨论了由此导致的实验与现实差距。从技术路线本身来看，这一不足并非不可解决——扩大预训练数据的分布覆盖即可缓解——但覆盖面的每一次扩展都意味着预训练成本的成倍增加，这是基础模型范式固有的工程矛盾。

6.4 未来方向

跨域零样本泛化。我们这次的核心发现之一是域匹配度对迁移学习性能的决定性影响。如何通过域适应技术使编码器表征对信道条件、带宽配置、信号制式等域偏移变量不敏感，是实现“零样本”频谱认知的关键突破口。可能路径包括对抗域分类器、扩大预训练数据分布覆盖、以及利用数字孪生生成高保真目标域数据。

多模态频谱感知。6G ISAC（通感一体化）是无线基础模型最具有希望的应用前景之一。当前的 LWM-Spectro 仅以单模态（频谱图）为输入，但完整的电磁环境感知需要融合来自通信信号、雷达回波、环境散射体、甚至视觉传感器和 LiDAR 点云的多模态信息。将频谱图与视觉、LiDAR 等数据共同编码到统一的嵌入空间中，使模型能够“既看到信号的频谱结构，也看到产生该信号的物理环境”——这是通向通用频谱认知的关键一步。MMSense 等工作已在这个方向做出了初步探索。

LLM驱动的Agent范式。本次实验中观察到的域匹配依赖性、任务非对称性和多任务梯度冲突，指向同一个根本问题：单一编码器难以在所有域、所有任务上同时达到最优。一个可能的替代思路是将频谱认知系统设计为Agent架构——以一个大语言模型作为调度核心，多个专用小模型作为可调用的感知专家。

在这一架构下，LLM并不直接处理频谱图。它的职责是理解任务指令、规划感知流程、决定调用哪些专家模型、融合多专家输出并生成可解释的结果。例如，当输入一段未知信号时，LLM可以先调用一个轻量的信号检测专家判断频段是否被占用；若检测到信号，再根据任务需求依次调用OFDM协议识别专家、调制分类专家或SNR估计专家；最后将各专家的输出整合为结构化报告。每个专家模型可以独立地在各自的域内以冻结编码器加轻量任务头的形式部署，避免了多任务联合训练中的梯度冲突问题。

这一范式的潜在优势在于：新增一种信号制式或感知任务时，只需训练一个新的专家模型并注册到Agent的调度列表中，无需改动已有的专家模型或重新训练整个系统。这实际上将“一次预训练、多次轻量适配”的基础模型范式，扩展为“多个专家、按需调度”的系统级架构。LLM在其中承担的是任务编排和上下文理解的职责——这些恰好是当前大语言模型已经展现出较强能力的方向。

边缘部署与模型压缩。本文已验证 LWM-Spectro 的 2.6M 参数量对边缘设备的部署性（约 10 MB 存储，~15 ms 推理延迟）。通过 INT8 量化、知识蒸馏、注意力

头剪枝等技术，可进一步压缩至约 2 MB、推理延迟约 5 ms，满足 6G URLLC 场景的实时频谱认知要求。

7 附录 A：完整信号生成代码

以下为 OFDM 协议信号生成与数据集构建的完整 Python 实现。

Listing 2: OFDM 信号生成核心代码

```

1 import numpy as np
2 from scipy.signal import stft
3
4 # ---- 星座映射 ----
5 def constellation(order):
6     if order == 2: # BPSK
7         return np.array([-1+0j, 1+0j])
8     pts = np.arange(-(int(np.sqrt(order))-1), int(np.sqrt(order)), 2)
9     c = np.array([x + 1j*y for x in pts for y in pts])
10    return c / np.sqrt((c.real**2 + c.imag**2).mean())
11
12 # ---- OFDM 符号生成 ----
13 def generate_ofdm_symbols(proto, mod_order):
14     """生成一帧 OFDM 信号 (多符号级联)"""
15     N_sc = proto["n_subcarriers"]
16     N_data = proto["n_data"]
17     cp_len = proto["cp_len"]
18     n_sym = proto["n_symbols"]
19     const = constellation(mod_order)
20
21     # ---- 导频位置 (BPSK 参考序列) ----
22     pilot_pos = proto["pilot_positions"]
23     data_pos = [i for i in range(1, N_sc//2)
24                 if i not in pilot_pos and i != 0]
25     pilot_vals = np.array([1+1j, 1-1j, -1+1j, -1-1j]) / np.sqrt(2)
26     pilots = np.tile(pilot_vals, (len(pilot_pos)+3)//4)[:len(pilot_pos)]
27
28     iq_signal = []
29     for _ in range(n_sym):
30         freq = np.zeros(N_sc, dtype=complex)
31         # 数据子载波
32         symbols = const[np.random.randint(0, mod_order, len(data_pos))]
33         for p, v in zip(data_pos, symbols):
34             freq[p] = v; freq[N_sc-p] = np.conj(v)
35         # 导频子载波
36         for p, v in zip(pilot_pos, pilots):
37             freq[p] = v; freq[N_sc-p] = np.conj(v)

```

```

38         # IFFT + CP
39         time_sym = np.fft.ifft(freq) * np.sqrt(N_sc)
40         cp = time_sym[-cp_len:]
41         iq_signal.append(np.concatenate([cp, time_sym]))
42     return np.concatenate(iq_signal)
43
44 # ---- AWGN 加噪 + STFT ----
45 def awgn(signal, snr_db):
46     pwr = np.mean(np.abs(signal)**2)
47     noise_pwr = pwr / (10**(snr_db/10))
48     n = np.sqrt(noise_pwr/2)*(np.random.randn(len(signal))
49                             + 1j*np.random.randn(len(signal)))
50     return signal + n
51
52 def to_spectrogram(iq):
53     f, t, Z = stft(iq, fs=1.0, window='hann',
54                    nperseg=128, noverlap=112, return_one_sided=False)
55     mag = np.abs(Z).T
56     mag = mag[:128, :128] if mag.shape[0] >= 128 \
57         else np.pad(mag, ((0, 128-mag.shape[0]), (0, 0)))
58     mag = np.log1p(mag)
59     return (mag - mag.min()) / (mag.max() - mag.min())

```

以下为 LWM-Spectro 编码器加载与下游训练的核心代码。

Listing 3: 编码器加载与分类头定义

```

1 import torch, torch.nn as nn
2 from pretraining.pretrained_model import LWM
3
4 # ---- 加载预训练编码器 (5G Expert) ----
5 def load_encoder(device):
6     ckpt = torch.load("moe_checkpoint.pth", map_location='cpu ',
7                       weights_only=False)
8     sd = ckpt['expert_state_dicts'][2]['state_dict']
9     new_sd = {}
10    for k, v in sd.items():
11        if k.startswith('model.backbone.'):
12            new_sd[k[15:]] = v
13    encoder = LWM(element_length=16, d_model=128, n_layers=12,
14                  n_heads=8, dropout=0.1, max_len=1025).to(device)
15    encoder.load_state_dict(new_sd, strict=False)
16    return encoder
17
18 # ---- 分类头 (残差 1D CNN + GAP + Linear) ----
19 class Classifier(nn.Module):
20     def __init__(self, encoder, n_classes, freeze_encoder=True):
21         super().__init__()
22         self.encoder = encoder
23         if freeze_encoder:
24             for p in self.encoder.parameters():
25                 p.requires_grad = False
26         self.head = nn.Sequential(
27             nn.Conv1d(128, 128, 3, padding=1), nn.BatchNorm1d(128),
28             nn.ReLU(), nn.Dropout(0.1),
29             nn.Conv1d(128, 128, 3, padding=1), nn.BatchNorm1d(128),
30             nn.ReLU(),
31             nn.AdaptiveAvgPool1d(1), nn.Flatten(),
32             nn.Linear(128, n_classes)
33         )
34     def forward(self, x):
35         # 4x4 patches -> 1024 tokens of 16 dims
36         patches = x.unfold(1, 4, 4).unfold(2, 4, 4)
37         patches = patches.contiguous().view(x.size(0), 1024, 16)
38         features = self.encoder(patches).transpose(1, 2)
39         return self.head(features)

```

8 附录 B：扩展实验分析

本附录补充在裸调制数据集上进行独立 SNR 回归和联合训练的详细训练曲线与 Per-SNR 分析。

8.1 独立 SNR 回归 Per-SNR 误差分解

表 13 列出了冻结编码器 SNR 回归在 7 个 SNR 级别上的逐档 MAE 误差。低 SNR (-5 dB) 和高 SNR (+25 dB) 两端误差较小 (0.32 dB 和 3.07 dB 的趋势受 ± 25 dB 区间的有限分辨能力影响)，而中等 SNR (15 dB) 误差最大 (2.26 dB)，这是因为 10–15 dB 区间信噪比适中时，不同调制类型的”表观噪声”差异最大 (BPSK 的稀疏星座 vs 256QAM 的稠密星座在相同噪声功率下呈现不同的谱形)。

表 13: 冻结编码器 SNR 回归 Per-SNR MAE

SNR (dB)	-5	0	+5	+10	+15	+20	+25
MAE (dB)	0.32	0.95	0.26	0.65	2.26	0.71	3.07

8.2 联合训练的收敛过程

表 14 记录了三种联合训练配置的训练日志片段，清晰展示了从初始梯度冲突到逐步收敛的过程。

表 14: 联合训练收敛过程 (Joint v2, 加深分类头)

Epoch	训练 Loss	验证调制 Acc	验证 SNR MAE
1	2.451	23.8%	8.12 dB
5	1.987	31.2%	4.56 dB
10	1.723	34.1%	2.89 dB
20	1.556	36.5%	1.98 dB
30	1.489	37.1%	1.72 dB
50	1.451	37.3%	1.60 dB

从表 14 可以观察到：(1) SNR 回归在训练早期 (Epoch 1–10) 快速改善 (8.12→2.89 dB)，这是因为全局功率统计信息的梯度信号更强、收敛更快；(2) 调制分类改善缓慢且幅度有限 (23.8%→37.3%)，需要 50 个 epoch 才能接近独立训练水平 (39.5%)；(3) 两条学习曲线的收敛速度差异恰好反映了两个任务对编码器表征提出的竞争性需求——SNR 需要全局、低维的信息 (容易学习)，调制需要局部、高维的纹理信息 (难以在域不匹配的编码器上学习到)。

8.3 微调训练曲线分析

图 15 展示了在裸调制数据集上全参数微调 50 个 epoch 的训练与验证准确率曲线。



图 15: 裸调制调制分类全参数微调的训练与验证准确率曲线

(训练准确率从初始20% 逐渐上升至约 42%，验证准确率在 39% 附近饱和。收敛速度缓慢)

我们从训练曲线中可以观察到：(1) 初始 5 个 epoch 内验证准确率从 20%（随机）快速跃升至约 30%，说明编码器最浅层的特征（例如 BPSK 的相位翻转条纹）可以被快速利用；(2) 5–30 epoch 之间准确率增长缓慢（30%→38%），表明底层特征需要大量的梯度迭代才能开始捕捉 QPSK/16QAM 之间细微的频谱纹理差异；(3) 30–50 epoch 进入平台期（~39%），训练准确率略高于验证准确率（约 3 个百分点的差距），提示模型开始对训练集中的特定噪声模式产生轻度过拟合。相比之下，域匹配的 OFDM 协议分类冻结方案在 Epoch 1 就达到 96.4% 验证准确率、Epoch 5 收敛至 98.8%——域不匹配时 50 个 epoch 的微调成果（39.5%）仍远低于域匹配时第一个 epoch 的冻结结果（96.4%）。

8.4 梯度冲突的定量分析

为进一步量化两个任务梯度的冲突程度，我们计算了共享编码器最后一层（Layer 12）上 SNR 损失梯度 $\mathbf{g}_{\text{SNR}}$ 与调制损失梯度 $\mathbf{g}_{\text{mod}}$ 的余弦相似度：

$$\cos(\mathbf{g}_{\text{SNR}}, \mathbf{g}_{\text{mod}}) = \frac{\mathbf{g}_{\text{SNR}} \cdot \mathbf{g}_{\text{mod}}}{\|\mathbf{g}_{\text{SNR}}\| \cdot \|\mathbf{g}_{\text{mod}}\|}$$

在 Joint (15 epoch) 配置中，该余弦相似度在训练全程维持在 -0.42 ± 0.15 范围内，始终为负值——两个梯度方向持续指向近乎相反的方向。Joint v2 通过加深分类头（增加了独立于编码器的非线性变换层数），余弦相似度改善至 -0.18 ± 0.12 ，部

分缓解了梯度冲突。这一发现对无线基础模型的多任务部署具有直接启示：在域不匹配条件下，与其试图在共享编码器上同时优化多个存在竞争的下游任务，不如为每个任务构建独立的任务头并分别训练，以避免共享编码器陷入梯度震荡。

8.5 裸调制微调各类别 F1 分数分析

图 16 展示了全参数微调后在裸调制数据集上各类别的 Precision、Recall 和 F1 分数。类间性能的极端不均衡清晰可见：BPSK 和 64QAM 的 F1 分数均超过 90%，而 QPSK 和 16QAM 的 F1 接近零。这种“两端高分、中间崩溃”的模式是域不匹配下迁移学习的典型特征——编码器在预训练中习得的特征仅与频谱图中两种极端纹理（极稀疏 vs 极稠密）产生偶然对齐，而中间状态（QPSK 的 4 点星座、16QAM 的 16 点星座）无法在编码器的特征空间中形成可分簇。




图 16: 全参数微调各类别 F1 分数

(BPSK (F1 $\approx$ 0.95) 和 64QAM (F1 $\approx$ 0.90) 远高于 QPSK/16QAM/256QAM (F1 $\approx$ 0))

8.6 域不匹配条件下 SNR 回归的额外验证

图 17 展示了来自服务器 (8 $\times$ RTX 4090, LTE Expert) 的 SNR 回归散点图，进一步验证了 SNR 回归在域不匹配条件下的鲁棒性。与图 12 (本地 4060, 5G Expert) 的结果一致，整体 MAE 维持在 1.16 dB 的优良水平。值得注意的是，使用 LTE Expert (而非 5G Expert) 的 SNR 回归 MAE 几乎完全一致 (1.16 vs 1.16 dB)，说明编码器中编码信号强度信息的方式对 Expert 选择不敏感——这是一种跨 Expert 一致的低维物理量编码。




图 17: 服务器端 SNR 回归散点图

(与本地 5GExpert 结果一致，验证 SNR 估计的跨 Expert 鲁棒性)

参考文献

- [1] ITU-R, “Framework and overall objectives of the future development of IMT for 2030 and beyond,” Rec. ITU-R M.2160-0, Nov. 2023.
- [2] N. Kim, S. Alikhani, and A. Alkhateeb, “LWM-Spectro: A Foundation Model for Wireless Baseband Signal Spectrograms,” *arXiv:2601.08780*, Jan. 2026.
- [3] H. Zou, Y. Tian, B. Wang, *et al.*, “RF-GPT: Teaching AI to See the Wireless World,” *arXiv:2602.14833*, Feb. 2026.
- [4] T. Yang, P. Zhang, M. Zheng, *et al.*, “WirelessGPT: A Generative Pre-trained Multi-task Learning Framework for Wireless Communication,” *arXiv:2502.06877*, Feb. 2025.
- [5] “ContraWiMAE: A Multi-Task Foundation Model for Wireless Channel Representation,” *arXiv:2505.09160*, May 2025.
- [6] A. Vaswani, N. Shazeer, N. Parmar, *et al.*, “Attention Is All You Need,” in *Proc. NeurIPS*, 2017.
- [7] J. Devlin, M.-W. Chang, K. Lee, *et al.*, “BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding,” in *Proc. NAACL-HLT*, 2019.
- [8] K. He, X. Chen, S. Xie, *et al.*, “Masked Autoencoders Are Scalable Vision Learners,” in *Proc. CVPR*, 2022.
- [9] A. van den Oord, Y. Li, and O. Vinyals, “Representation Learning with Contrastive Predictive Coding,” *arXiv:1807.03748*, 2018.
- [10] A. Alkhateeb, “DeepMIMO: A Generic Deep Learning Dataset for Millimeter Wave and Massive MIMO Applications,” in *Proc. ITA*, 2019.